

Soluciones Trabajo práctico 1: STATA

- I. Genere una variable llamada "alq" que reporte el valor que pagan los inquilinos por su alquiler, y el valor al que alquilarían la vivienda los propietarios.

Comencemos buscando información básica sobre las variables en cuestión¹. Tendremos que trabajar con la variable *alq*, sobre alquileres, y con la variable *condprop* que nos informa la condición de tenencia. Utilizando el comando *describe* accedemos a información básica sobre una variable. Al tipear:

```
. describe condprop
```

variable name	storage type	display format	value label	variable label
condprop	float	%18.0g	tenure	

Nos revela que la variable tiene una etiqueta denominada "tenure". Podemos ver el contenido de la etiqueta *tenure* con el comando *label list*:

```
. label list tenure
```

- 1 Propietario
- 2 Inquilino
- 3 Ocupante c/permiso
- 4 Ocupante s/permiso

Nos informa que *tenure* asigna una etiqueta de "propietario" cada vez que la variable *condprop* tome el valor 1, la etiqueta "inquilino" cada vez que la variable tome el valor 2 y así.

Por otra parte, si tipeamos:

```
. table condprop
```

condprop	Freq.
Propietario	859
Inquilino	435
Ocupante c/permiso	111
Ocupante s/permiso	11

Obtuvimos la frecuencia de observaciones de cada una de las categorías. Es decir, 859 hogares en la base tienen a jefes de hogar como propietarios, 435 son inquilinos, y así...

¹ Recuerden que la base original tenía inconsistencias que corregí y les mandé una versión arreglada.

Definimos entonces la variable `alq` como los valores de `valalq` si la observación del hogar respectivo corresponde a un inquilino y los valores de `propalq` si la observación respectiva corresponde a un propietario. Recordemos que para generar una variable usando un criterio lógico podíamos usar el comando *generate*, y que este comando debe ser combinado con el comando *replace* para generar modificaciones. De la siguiente forma:

```
generate alq=valalq if condprop==2  
replace alq=propalq if condprop==1
```

Alternativamente podríamos también haber hecho:

```
generate alq=valalq if condprop==2  
replace alq=propalq if alq==.
```

De esta última manera lo que hicimos fue reemplazar los valores que quedaron missing (".") luego del primer comando, por aquellos valores de alquiler que contiene `propalq`.

II. Genere una nueva variable llamada a "logalq" que reporte el logaritmo del valor de alquiler.

Aquí utilizamos nuevamente el comando *generate*, que nos permite generar nuevas variables en base a cuentas o cálculos completamente definidos. Simplemente hacemos:

```
generate logalq=log(alq)
```

Como `log` es una función matemática, se la utiliza en este caso directamente sobre la variable `alq`.

III. En base a la variable `alq`, elabore una tabla que reporte los valores promedios de alquiler por barrio. Incorpore también los valores correspondientes a las medianas².

Para realizar la tabla, recordemos que la sintaxis del comando `table` dice:

```
table rowvar [colvar [supercolvar]] [if] [in] [weight] , contents(clist)
```

Es decir, la variable que irá a las filas de la tabla es la que se debe incorporar inmediatamente después del comando *table*.

Como parte de las opciones tenemos que describir cuál será el contenido de las celdas. Recordemos que debemos especificar el estadístico en cuestión seguido del nombre de la variable. En este caso nos interesa el promedio (el estadístico *mean*) y la mediana (el estadístico *median*).

```
table barrio, c(mean alq median alq)
```

² Ya que los barrios de Parque Patricios y Barracas fueron relevados en Mayo 2009, mientras que el resto en Noviembre 2007, se procedió a ajustar estos últimos por índices de inflación basados en la publicación de la Ciudad sobre precios de propiedades.

Obtenemos:

barrio	mean(alq)	med(alq)
Avellaneda	1418.572	1112
Caballito	1576.795	1400
Palermo	1423.719	1404
S. Cristobal	1183.686	1112
Parque Patricios	1305.828	1200
Barracas	1314.968	1200

Notar que sin tomar en consideración las características de los inmuebles incorporados en la muestra, los resultados sugieren que los barrios más costosos son Caballito y Palermo (con un valor mediano de \$1400), seguido por Barracas y Parque Patricios (mediana de \$1200). Notar que en el caso de Caballito, el valor promedio es sensiblemente mayor que la mediana, lo que sugiere la presencia de alguna observación atípicamente alta que sesga el promedio.

IV. Genere una variable dummy para cada una de las siguientes características de las viviendas: i) presencia de jardín, ii) presencia de cochera, iii) el inmueble es una casa, iv) el respondiente es el propietario del inmueble.

Utilizaremos nuevamente los comandos `generate` y `replace` para generar las variables dummies. Denominaremos a las dummies anteponiendo un prefijo “d”. Para los casos de la variable de jardín y de cochera tenemos que la variable toma el valor 1 si hay presencia de ese atributo, 2 si no hay presencia del mismo y 99 si la persona no sabe o no contesta (chequear las etiquetas si es necesario). Lo que haremos entonces es generar nuevas variables que tomen el valor 1 o 0 de acuerdo a la definición de variables binarias. Así también consideraremos que las observaciones 99 quedarán fuera del análisis, para ello las reemplazaremos por un valor missing (“.”).

```
generate djardin=1 if jardin==1
replace djardin=0 if jardin==2
replace djardin=. if jardin==99
```

```
generate dcochera=1 if cochera==1
replace dcochera=0 if cochera==2
replace dcochera=. if cochera==99
```

Para la variable dummy si es una casa, la definición de la variable *casaodep* incorpora también la categoría ph y la categoría “otro”. Para simplificar la sintaxis, en el segundo paso especificamos que la variable dummy tomará todo el valor 0 para todo aquel valor que no sea 1, de la siguiente forma:

```
generate dcasa=1 if casaodep==1
replace dcasa=0 if casaodep!=1
replace dcasa=. if casaodep==99
```

Donde “!=” es el símbolo lógico que indica que es distinto. Análogamente para el caso del jefe es propietario:

```
generate dpropietario=1 if condprop==1
replace dpropietario=0 if condprop!=1
replace dpropietario=. if condprop==.
```

- V. Elabore tab las de car acterísticas de la s viviendas p or barrio, qu e reporten el porcentaje de vivien das con jardín, el porcentaje de vi viendas con cochera, porcentaje de casas, porcentaje de propietarios. Interprete los resultados.

Para obtener una tabla con porcentajes por barrio, aprovechamos el hecho de que para cada una de las variables mencionadas ya generamos una variable dummy y de que el promedio de una variable dummy para una cierta variable o rango de la misma será equivalente a calcular el porcentaje de valores “1”. Por ejemplo, supongamos que la variable djardín, para el barrio de Caballito toma los valores {1,0,0,1,0}, entonces el promedio de la variable en Caballito es $= (1+0+0+1+0)/5=0.4$, por lo que el porcentaje es 40%.

Por lo tanto necesitamos calcular el estadístico media en los subgrupos de observaciones dados por el barrio. Usamos nuevamente el comando table:

table barrio, c(mean djardin mean dcochera mean dcasa mean dpropietario)

Obtenemos:

barrio	mean(djardin)	mean(dcochera)	mean(dcasa)	mean(dpropietario)
Avellaneda	0.534	0.481	0.782	0.647
Caballito	0.249	0.308	0.167	0.556
Palermo	0.314	0.279	Es 0.358	0.558
S. Cristobal	0.230	0.103	0.293	0.574
Parque Patricios	0.789	0.261	0.625	0.610
Barracas	0.770	0.332	0.636	0.695

- VI. Clasifique las viviendas según el valor de alquiler en tres grupos llam ados “baratas”, “medianas”, “caras”, de la siguiente forma: i) Genere una variable que para cada barrio contenga el percentil 33 del valor del alquiler y otra variable que para cada barrio contenga el percentil 66 del alquiler; ii) Luego genere una variable clasificatoria que tome que tome el valor “barata” si el valor del alquiler es menor al percentil 33 en el respectivo barrio, el valor “mediana” si es mayor al percentil 33 y menor al 66, y “cara” en otro caso. Luego complete el siguiente cuadro:

Una alternativa para generar percentiles es utilizar el comando egen, que como explicamos sirve para generar variables utilizando funciones predeterminadas. Una de las funciones disponibles del comando *egen* es *pctile* (ver la página de ayuda de egen tipeando “help egen”). Para obtener el percentil 33 de la variable alq, el comando será:

egen alqp33=pctile(alq), p(33)

Donde alqp33 es el nombre que le dimos a la nueva variable que reportará, en todos sus valores, el valor correspondiente al percentil 33; y p(33) es la opción que nos permite identificar el percentil deseado.

Sin embargo, en este caso necesitamos adicionalmente que el percentil reportado corresponda a cada subgrupo de observaciones definidos según la variable barrio. Para poder definir el comando *egen* en subgrupos de observaciones podemos combinar el mismo con el prefijo *bysort*. Recordemos que sólo algunos comandos son combinables con el prefijo *by* (i.e.: separar por grupos según una variable) y *bysort* (i.e., ordenar las observaciones de menor a mayor o alfabéticamente según corresponda y luego separar por grupos según una variable). En este caso el comando será:

```
bysort barrio: egen alqp33=pctile(alq) , p(33)
```

```
bysort barrio: egen alqp66=pctile(alq) , p(66)
```

Una vez que tenemos variables que nos permiten, para cada observación, conocer el percentil 33 y el percentil 66 respectivo, sólo nos resta comparar el alquiler de cada observación con estos datos para determinar si la misma corresponde a la categoría de “barata”, “mediana” o “cara”. Para generar la variable clasificatoria usamos el comando *generate* (y luego *replace*) y el condicional *if* para realizar las comparaciones:

```
generate alqclasif="barata" if alq<alqp33
```

```
replace alqclasif="mediana" if alq>=alqp33 & alq<alqp66
```

```
replace alqclasif="cara" if alq>alqp66
```

Por último, para generar una tabla de doble entrada usamos el comando *table*:

```
table alqclasif barrio, c(mean chabviv)
```

Obtenemos:

alqclasif	barrio					
	Avellaneda	Caballito	Palermo	San Cristobal	Parque Patricios	Barracas
barata	2.311	1.979	2.036	2.275	2.674	2.750
cara	3.303	2.869	3.029	2.912	4.757	4.424
mediana	2.886	2.381	2.231	2.298	3.359	3.356

VII. Estime el siguiente modelo econométrico mediante Mínimos Cuadrados Ordinarios (MCO): Interprete los componentes de salida de regresión que se presentaron en clase.

El modelo propuesto es:

$$\log(alq) = \beta_0 + \beta_1 * \text{jardín} + \beta_2 * \text{garage} + \beta_3 * \text{propietario} + \beta_4 * \text{cbanhos} + \beta_5 * \text{chabviv} + \varepsilon$$

Para estimar el modelo mediante el método de mínimos cuadrados, utilizamos el comando *regress*:

```
regress logalq djardin dcochera dpropietario dcasa chabviv cbanhos
```

El programa nos muestra la siguiente salida de regresión:

Source	SS	df	MS	Number of obs	=	969
				F(6, 962)	=	71.09
Model	59.5698746	6	9.92831243	Prob > F	=	0
Residual	134.35663	962	0.139663856	R-squared	=	0.3072
				Adj R-squared	=	0.3029
Total	193.926504	968	0.200337298	Root MSE	=	0.37372

logalq	Coef.	Std. Err.	t	P>t	[95% Conf. Interval]	
djardin	-0.0640	0.0263	-2.43	0.015	-0.1156	-0.0123
dcochera	0.1814	0.0300	6.04	0	0.1224	0.2404
dpropietario	0.2113	0.0268	7.9	0	0.1588	0.2639
dcasa	-0.0785	0.0277	-2.83	0.005	-0.1329	-0.0240
chabviv	0.0553	0.0102	5.44	0	0.0353	0.0752
cbanios	0.1489	0.0224	6.65	0	0.1049	0.1928
_cons	6.6276	0.0311	212.9	0	6.5666	6.6887

La salida de regresión nos sugiere los siguientes resultados: i) El modelo se estimó en base a 969 observaciones (esta reducción con respecto al número original en la base se debe a que éstas son las observaciones para las cuales ninguna variable incluida en la regresión presenta valores faltantes (missing values). Es decir, si alguna variable tenía un valor missing en alguna observación, el programa automáticamente elimina la observación completa de las que utilizará para computar los estimadores. ii) El test F de significatividad conjunta (bajo la hipótesis nula de modelo conjuntamente no significativo) presenta un estadístico asociado a una probabilidad casi 0 (Prob>F=0). Esto puede sonar confuso, pero es correcto: En otras palabras, en este caso asumimos cierto valor para el estadístico del test (la llamada hipótesis nula, que en este caso asume que el modelo no es significativo), y el resultado que surge tiene asociada una probabilidad de ocurrencia casi 0, implicando que la hipótesis debe ser rechazada (i.e., una hipótesis sobre el verdadero valor del coeficiente será aceptada sólo si el coeficiente que es estimado está asociado a una probabilidad alta de ocurrencia). Al rechazar la hipótesis rechazamos que el modelo sea conjuntamente no significativo. (i.e., el modelo sería significativo). iii) El R-cuadrado de la regresión (0.31) sugiere que el modelo logra explicar un 31% de la variabilidad presente en los datos de alquileres. iv) Los tests de hipótesis de los coeficientes encontrados (hipótesis nula de efecto nulo) sugieren que cada una de las variables explicativas es significativa. Cada una de las variables explicativas presenta valores t absolutos mayores que 2, y esto se relaciona con una probabilidad de ocurrencia del coeficiente estimado casi nula (probabilidad siempre menor que un 5% (0.05)). Vi) Las viviendas que son casas o poseen un jardín se relacionan con un menor alquiler (con un efecto de un 6% menor alquiler en el caso de tener jardín y un 7% menor alquiler en el caso de ser una casa. siempre todo lo demás es constante). Aquellas viviendas en las que habita el propietario se relacionan con un alquiler un 20% mayor, y las que tienen cochera un 18% mayor. Un baño adicional representa un alquiler 5% mayor y una habitación adicional un 5% mayor.

VIII. El archivo calidadnotasbarrio.dat contiene las calificaciones subjetivas otorgadas por los vecinos a las características del barrio. Incorpore esta información a la base

de datos calidad .dat y genere una tabla que reporte el promedio de cada una de estas variables por barrio.

Para agregar las variables contenidas en el archivo calidadnotasbarrio.dat a la base que utilizamos, usaremos el comando merge. La base con la que venimos trabajando es la que llamaremos “master data” y la base de donde extraeremos la información es la “using data”. Adicionalmente, para agregar las bases debemos indicar aquella variable que es común a ambas y que servirá para asignar correctamente a cada observación de la base master, la correspondiente observación de la using. En nuestro caso esta variable es el número de encuesta: *Nroenc*.

Recordemos también que para hacer el merge, previamente las bases *master* y *using* deben estar ordenadas según la variable que se utilizará como nexo. Por eso es probable que necesitemos indicar: `sort nroenc`

En caso de que surja un mensaje de error “using data not sorted”, entonces deberemos cerrar la base con la que estamos trabajando (guardando los cambios), abrir la base using, ordenar usando el comando sort, guardar los cambios, cerrar la base y volver nuevamente a la master data antes de correr el merge.

La sintaxis del comando merge requiere que especifiquemos la variable nexo (nroenc) seguida de la especificación completa del directorio donde se ubica el archivo de la base *using*. El comando completo será:

```
merge nroenc using "C:\Users\r\Documents\Taller\calidadnotasbarrio.dta"
```

IX. Estime nuevamente el modelo de regresión de determinantes de los alquileres incorporando alguna de las calificaciones subjetivas como variable explicativa. Interprete y comente los resultados.

A continuación se estima el modelo incorporando la variable subjetiva de calificación de estado de las calles llamada (calles_nota).

Los coeficientes estimados y sus tests de significatividad asociados son los siguientes:

logalq	Coef.	Std. Err.	t	P>t	[95% Conf.	Interval]
djardin	0.0120406	0.0443434	0.27	0.786	-0.075214	0.099295
dcochera	0.1421404	0.0460244	3.09	0.002	0.0515783	0.232703
dpropietario	0.3446417	0.0411328	8.38	0	0.2637049	0.425578
dcasa	0.0219751	0.0425726	0.52	0.606	-0.061795	0.105745
chabviv	0.0558674	0.0140279	3.98	0	0.0282648	0.08347
cbanios	0.0828713	0.0364845	2.27	0.024	0.0110808	0.154662
calles_nota	0.0002648	0.007301	0.04	0.971	-0.014102	0.014631
_cons	6.494221	0.0662805	97.98	0	6.363801	6.624641

Podemos observar que la nueva variable explicativa no resulta un determinante significativo del valor de alquiler. Bajo la hipótesis de no significatividad, el valor estimado se encuentra asociado a una probabilidad de ocurrencia alto (0.97), es decir, la evidencia no permite rechazar la hipótesis nula, por lo tanto se concluye que la variable posee un efecto no significativamente distinto de 0 (la calificación subjetiva de calles no tiene efecto en el alquiler).

Así también, la introducción de esta variable en el análisis, al modificar los estadísticos de las demás variables, resulta en que la presencia de jardín y la dummy de casa no presenten significatividad. Esto

podría deber a cierta colinealidad entre la nueva variable y las dos mencionadas, que resulta en un aumento de los errores estándar estimados (y por lo tanto también en un menor valor del estadístico T, que no permite rechazar la hipótesis de no-significatividad).